

Arquitetura Robusta para Alinhamento Semântico e Geométrico de Anotações Qualitativas em Matrizes PDF

1. Contextualização e Diagnóstico do Ecossistema Atual

A interoperabilidade de dados qualitativos entre plataformas analíticas dedicadas, como o Atlas.ti, e ambientes de renderização de leitura integrados, como o ecossistema PDF.js dentro do Obsidian, impõe um desafio substancial de alinhamento de estruturas de dados. O formato QDPX exporta seleções baseadas na interpretação semântica e sequencial do motor de extração nativo do software de origem. Em contrapartida, a biblioteca PDF.js reconstrói a camada textual (text layer) de forma puramente visual, instanciando nós do *Document Object Model* (DOM) a partir de instruções de desenho vetorial e posicionamento absoluto de glifos. Esta assimetria ontológica resulta em divergências críticas relacionadas à hifenização, concatenação de ligaturas tipográficas, ordem de leitura espacial (reading order) e intrusão sistemática de elementos de leiaute, tais como cabeçalhos, rodapés e tabelas¹.

A análise do repositório alvo e dos artefatos produzidos pelos testes de fumaça (*smoke tests*) manuais demonstra que o sistema atual possui um *baseline* estruturalmente impecável, mas visualmente imperfeito. O contrato de integração estabelece requisitos draconianos: preservação absoluta de 203 marcadores textuais sem qualquer conversão de contingência para formas geométricas (*PdfShapeMarker*), garantia de zero pendências (marcadores não resolvidos) e manutenção irrestrita das semânticas de páginas adjacentes⁴. O sistema atual atende a este contrato estrutural de forma integral, mas a auditoria de cobertura visual (*coverage audit*) revelou 21 instâncias de incompatibilidade (*mismatches*), que representam 10,34% do volume total de marcadores.

A tabela a seguir categoriza detalhadamente a fenomenologia destes desvios para embasar a formulação arquitetural subsequente.

Classe de Divergência	Frequência	Descrição do Comportamento Observado no PDF.js	Impacto Semântico e Estrutural
<i>Covered-prefix</i> (Truncamento)	16 ocorrências	A âncora inicial é identificada corretamente, mas o algoritmo de expansão	O marcador existe e inicia no local correto, porém a evidência visual apresentada ao

		interrompe o percurso precocemente. Ocorre frequentemente devido a divergências de texto (ligaturas, espaços fantasmas) ou quebras de bloco geométrico.	investigador humano é incompleta.
<i>Covered-inside-expected</i> (Deslocamento Interno)	3 ocorrências fora do documento D1	O marcador é posicionado no interior do trecho original esperado. O algoritmo falhou em reconhecer as palavras iniciais, frequentemente devido a anomalias severas de OCR ou hifenização translinear no limite da âncora.	Perda parcial de contexto inicial. O sistema ancorou no primeiro segmento em que obteve confiança ininterrupta.
Falsos Positivos de Localização	2 ocorrências graves (Documento D1)	O texto procurado é localizado num texto padronizado (<i>boilerplate</i> , licenças, metadados de rodapé) em vez do corpo principal do artigo. O sistema classifica como <i>covered-inside-expected</i> , mas a localização no documento é incorreta.	Erro grave de integridade de dados. A anotação qualitativa é transposta para um contexto irrelevante, invalidando a inferência do pesquisador.

A análise profunda do módulo `resolvePendingIndices.ts` revela que a raiz fundamental destas patologias de importação reside na confusão algorítmica entre duas responsabilidades sistêmicas intrinsecamente distintas: a localização da âncora inicial e a determinação da extensão final do marcador. O sistema atual opera mediante uma cascata de tentativas lineares, unificando a extração do texto da página numa cadeia contígua e aplicando estratégias de correspondência literal, normalizada ou contextual.

Tentativas anteriores de mitigar os erros resultaram em falhas instrutivas. A expansão textual ampla, que permitia ao marcador crescer indefinidamente enquanto a chave normalizada apresentasse similaridade, provocou o vazamento transversal de seleções para tabelas e rodapés, demonstrando que a continuidade puramente lexical é insuficiente em arranjos acadêmicos complexos. Por outro lado, a imposição de regras de validação binária severas na âncora (rejeitando candidatos que não coincidissem perfeitamente nos primeiros 32 caracteres) destruiu a estabilidade estrutural do sistema, atirando 38 marcadores para o limbo das pendências. Conclui-se que transformar a plausibilidade contextual num filtro obrigatório binário é um antipadrão arquitetural; o sistema não deve punir o marcador inteiro pela incapacidade de alinhar uma fração de caracteres corrompidos pelo reconhecimento óptico de caracteres (OCR) ou por processamento anômalo da camada de texto.

2. Separação de Preocupações: A Dicotomia entre Âncora e Extensão

A fundação para um resolvedor robusto exige a adoção de um paradigma de separação estrita de subproblemas. A recuperação de informações em documentos não estruturados, como é o caso intrínseco dos PDFs, requer abordagens divergentes para encontrar o início de uma entidade e delimitar suas fronteiras lógicas⁵.

2.1 O Subproblema da Localização da Âncora

Encontrar a âncora inicial consiste em identificar a coordenada de partida no *Document Object Model* (o índice do `.textLayerNode` e o deslocamento de caracteres associado) que representa o início semântico da seleção importada do Atlas.ti. Este é classicamente um problema de Recuperação da Informação (*Information Retrieval*) e de Alinhamento Local de Sequências, que deve ser concebido para possuir altíssima resiliência a ruídos locais⁸.

A premissa basilar é que a âncora não precisa, e em muitos casos não pode, ser a primeira palavra exata da *string* de origem. Se o trecho original inicia-se com uma palavra contendo ligaturas tipográficas complexas (como ffi, fl, st) que a biblioteca gráfica do Mozilla traduziu de maneira fraturada, exigir um acerto (*match*) no prefixo resultará em rejeição². Além disso, diferenças de ordenação de leitura podem inserir quebras de página numéricas, notas de rodapé flutuantes ou números de linha algures no meio do texto esperado. O sistema deve possuir a capacidade de identificar uma "janela interna" de altíssima confiança, utilizando o contexto adjacente e heurísticas geométricas como a caixa delimitadora (`bbox`) para retroceder e fixar a âncora de forma probabilística.

2.2 O Subproblema da Determinação da Extensão

Uma vez que a âncora foi estabelecida com um nível aceitável de confiança, o sistema transita para um domínio problemático inteiramente diferente: a Análise de Leitura de Documentos (*Document Layout Analysis* - DLA). Determinar a extensão da seleção não é um processo de busca de texto, mas um processo de navegação topológica⁶.

A ocorrência persistente de *covered-prefix* demonstra que o motor de correspondência interrompe sua progressão assim que depara com uma divergência inaceitável no fluxo da camada textual⁴. Em periódicos acadêmicos (como os modelos IEEE e Nature frequentemente encontrados no artefato D1 e congêneres), o texto flui através de múltiplas colunas e salta sobre matrizes de dados e ilustrações¹². Para garantir que a extensão do marcador cubra todo o trecho esperado sem vazar para metadados ou páginas marginais adjacentes, a continuidade deve ser provada continuamente por duas frentes simultâneas: a coesão léxica restante em relação à *string* do QDPX e a coesão do bloco geométrico subjacente. A semântica da função `resolveOnNeighborPage()`, que transita no vetor `[pageNumber - 1, pageNumber + 1]`, deve ser compreendida não como uma varredura lexical cega nas páginas vizinhas, mas como a ponte geométrica entre o encerramento do último fluxo de leitura de uma página e o início do primeiro fluxo de leitura da página subsequente¹³.

3. Localização Robusta de Âncoras via Alinhamento Local de Sequências

As abordagens tradicionais que envolvem comparações de *strings* exatas, normalização de espaços em branco ou substituição de chaves alfanuméricas por expressões regulares ignoram a natureza caótica da extração textual em PDFs. A aplicação de regras de normalização de ligaturas codificadas rigidamente (como as conversões literais de `fff` para `ffi` presentes no histórico do código) constitui uma heurística frágil que não generaliza para diferentes motores de PDF ou idiomas exóticos, arriscando causar regressões severas em outras partes do documento¹⁵. A solução definitiva e cientificamente validada para o alinhamento de textos ruidosos contra fontes externas limpas repousa sobre a adoção de algoritmos de Programação Dinâmica oriundos da Bioinformática, especificamente o algoritmo de Smith-Waterman¹⁵.

3.1 A Superioridade do Algoritmo de Smith-Waterman

Diferentemente do algoritmo Needleman-Wunsch, que busca forçar um alinhamento global de ponta a ponta penalizando extensivamente as disparidades iniciais e terminais, o algoritmo de Smith-Waterman executa um alinhamento local¹⁵. Ele identifica os subtrechos de maior similaridade no interior de sequências maiores, descartando regiões periféricas mal conservadas⁸. Esta característica é de utilidade incomensurável para o problema de *covered-inside-expected* e truncamento de sufixos.

A implementação exige a construção de uma matriz de pontuação onde as semelhanças e disparidades são computadas de forma iterativa. Para evitar os clássicos "efeitos de mosaico" ao alinhar caracteres provenientes de OCR ruidoso, é imperativo o uso do modelo de penalidades de lacuna afins (*affine gap penalties*), formalizado na extensão de Gotoh¹⁶.

A equação central para o preenchimento da matriz de pontuação $H(i, j)$ ao alinhar o texto

do Atlas.ti (A) e o fragmento candidato do PDF.js (P) é expressa por:

$$H(i, j) = \max \begin{cases} 0 \\ H(i-1, j-1) + s(a_i, p_j) \\ \max_{k \geq 1} \{H(i-k, j) - W_k\} \\ \max_{l \geq 1} \{H(i, j-l) - W_l\} \end{cases}$$

Nesta formulação matemática, a função de similaridade $s(a_i, p_j)$ recompensa acertos exatos entre os caracteres (ou *tokens*) com valores positivos elevados, e pune discrepâncias (substituições errôneas típicas de falha visual, como a confusão entre 'e' e 'c') com valores moderadamente negativos¹⁶. O termo diferencial reside na função de penalidade de lacuna afim W_k :

$$W_k = \gamma_{open} + k \cdot \gamma_{extend}$$

A variável γ_{open} aplica um custo substancial pela criação inicial de um espaço no texto (um *gap*), refletindo o custo cognitivo de uma interrupção inesperada no fluxo de leitura (uma quebra de linha artificial, um hífen inserido, ou a omissão de uma letra devido a uma ligatura

não processada). A variável γ_{extend} estabelece um custo muito menor, muitas vezes fracionário, para a continuação dessa mesma lacuna¹⁵.

A generalização desta heurística para múltiplos PDFs é inquestionável: ela modela a própria estrutura de geração do erro. Se uma ligatura fl for traduzida pela camada gráfica como f l ou omitida por completo, o algoritmo de Smith-Waterman absorverá o impacto através de uma única penalidade de abertura de lacuna e retomará a alta pontuação no caractere imediatamente subsequente, garantindo um índice de similaridade perfeitamente adequado para a fixação da âncora⁸. Este método extingue a necessidade de normalização prévia por supressão arbitrária de caracteres especiais ou tabelas exaustivas de apelidos (*aliases*) tipográficos.

3.2 Eficiência Computacional e Janelamento Direcionado

A complexidade de tempo e espaço do algoritmo de Smith-Waterman tradicional é

$O(m \cdot n)$, o que representa um custo proibitivo se for aplicado indiscriminadamente a todo o conteúdo textual de uma página acadêmica complexa¹⁵. Consequentemente, a sua implementação no contexto da extensão para Obsidian não deve ocorrer em nível global. O algoritmo deve ser invocado em janelas internas restritas. O sistema inicializa a busca

extraindo representações em *n-gramas* robustos do marcador do QDPX (por exemplo, as primeiras 15 letras válidas ou um conjunto de palavras centrais). Uma busca relâmpago indexada, utilizando algoritmos de subcadeia de menor complexidade, identifica as regiões de interesse (*candidate zones*) no *buffer* do texto do PDF. O Smith-Waterman é então focalizado estritamente nessas zonas para computar os limites exatos do alinhamento. Estudos sobre adaptação deste modelo para processamento de linguagem natural (PLN) demonstram que restrições espaciais prévias mantêm a latência de execução no limite da aceitabilidade das interfaces de utilizador baseadas na *web* ou em arquiteturas Electron⁹.

4. Disambiguação Contextual Inspirada no W3C Web Annotation

Em situações em que o Smith-Waterman acusa índices marginais de similaridade, o risco de atrelar a anotação ao texto *boilerplate* — gerando os graves erros de falso positivo visíveis nos testes do Documento D1 — aumenta exponencialmente. O algoritmo encontra a *string* correta na nota de rodapé com permissão de direitos de autor, em detrimento do corpo do texto, porque localmente ambas as sequências textuais são idênticas.

Para remediar esta ambiguidade sem recorrer a identificadores proprietários ou formatações exclusivas de editoras, a arquitetura deve beber da sabedoria do padrão W3C Web Annotation Data Model, especificamente na implementação do Hypothesis e seus construtos de ancoragem múltipla¹⁹.

O modelo W3C não confia na localização pura; ele empilha seletores redundantes para descrever um único trecho de interesse. A classe `TextQuoteSelector` encerra o trecho exato pretendido acompanhado dos atributos críticos `prefix` (o pequeno contexto imediato que precede o alvo) e `suffix` (o contexto imediato que o sucede)²¹. A classe `TextPositionSelector` registra os índices numéricos absolutos, conferindo uma restrição espacial²⁰.

O artefato `importedPdfTextContext` proveniente do QDPX atua precisamente como um `TextQuoteSelector` nativo. O sistema atual já tenta avaliar o contexto de texto simples importado, mas fá-lo numa lógica de substituição. Na nova arquitetura, o alinhamento contextual não é um caminho condicional, mas um peso numérico somado à avaliação contínua. Quando a localização do texto alvo for dúbia (dois ou mais locais com alta similaridade), a presença do prefixo e sufixo ditados pelo `importedPdfTextContext` num raio próximo às adjacências do nó DOM atua como o vetor absoluto de desempate, ancorando a seleção no corpo da literatura e rejeitando inapelavelmente os cabeçalhos recorrentes²¹.

5. Geometria Segura: Extensão Limitada por Análise de Leiaute Topológico

A cláusula irreduzível do contrato de modernização dita que a geometria (blocos, linhas e caixas) deve auxiliar a localização, mas as seleções textuais estritas *nunca* devem ser convertidas num polígono, retângulo ou num `PdfShapeMarker` caso haja falhas na evidência. Isto exige uma manipulação cautelosa das informações posicionais dos `textLayerNodes`. O PDF.js entrega a matriz de transformação para cada fragmento de texto, a qual exige correção em relação à origem padrão do PDF (base-esquerda) para a origem do HTML Canvas

(topo-esquerdo), descrita pela relação $[x \cdot s, h_{canvas} - (y + altura) \cdot s]$ ²⁴.

Uma expansão contínua não pode se fiar apenas nas sequências de caracteres porque, em revistas multiculunas, as matrizes espaciais sobrepõem-se na linearização burra. Para estender com segurança o realce a partir do início descoberto até ao final exato, necessitamos de um agrupamento coerente através da Análise Geométrica de Leiaute (DLA).

5.1 O Modelo Recursive XY-Cut Otimizado

A literatura especializada abarca métodos sofisticados de *clustering* bidimensional (como o algoritmo de vizinho mais próximo ascendente, o Docstrum⁵), mas para um ambiente de tempo real processado no cliente Obsidian, a leveza impõe preferência pelos métodos clássicos baseados em projeção top-down, especificamente uma variação rápida do algoritmo de Corte XY Recursivo (*Recursive XY-Cut* - RXYC) adaptado para limites de caixas já disponíveis no DOM⁶.

O algoritmo RXYC opera fatiando a página retangular em segmentos cada vez menores, aproveitando os "vales" (zonas de zero densidade de texto) obtidos ao projetar os pixels escuros — ou, no nosso caso, os vértices dos *bounding boxes* dos nós textuais — sobre os eixos horizontal e vertical⁵.

A implementação proposta para o resolvidor processa-se em passos explícitos sem construir renderizações visuais pesadas:

1. **Iteração de Entidades:** O algoritmo compila um vetor rápido com os vértices originais (X_{min} , Y_{min} , X_{max} , Y_{max}) extraídos de todos os nós presentes no textLayer.
2. **Projeção Horizontal (Identificação de Linhas):** A densidade cumulativa das alturas é projetada sobre o eixo Y. Segmentos contíguos onde a densidade cai a zero representam o espaço entre as linhas (entrelinha). O algoritmo agrupa os nós adjacentes em estruturas lógicas de "Linhas"⁶.
3. **Projeção Vertical (Identificação de Colunas):** Com os agrupamentos horizontais definidos, a densidade de largura projetada no eixo X identifica os "vales" verticais substanciais. Vales que partem o eixo X inteiramente através do corpo de texto sinalizam as separações magnas de colunas ou blocos lógicos disjuntos¹¹.

O produto deste processamento é uma árvore topológica hierárquica imaterial, construída exclusivamente na memória durante a vigência do pageObserver. O nó 43 não é apenas o caractere de índice 3120; o nó 43 pertence agora, geometricamente, à Linha 14 da Coluna Esquerda do Bloco Principal.

5.2 A Lógica de Expansão e o Percurso Condicionado

Esta árvore topológica orienta o motor de extensão (o passo após ancoragem). Partindo do nó DOM seguro retornado pelo algoritmo de Smith-Waterman, o extensor prossegue consumindo os nós seguintes no sentido literal, acumulando similaridade léxica. A transição de um nó para o outro na camada textual submete-se ao interrogatório geométrico contínuo:

- Se o nó subsequente pertencer à **mesma Linha** topológica, a expansão prossegue sem penalidade.
- Se o nó subsequente pertencer à **Linha adjacente inferior** no mesmo Bloco, a expansão

- consome a quebra de linha visual de forma segura.
- Se o nó subsequente indicar um salto para uma **Coluna distinta** ou um Bloco superior adjacente, a expansão só é autorizada se o índice contínuo de coesão léxica mantiver-se superior a um limiar severo. Uma transição de bloco representa sempre um risco acentuado de invasão em tabelas intercaladas e caixas marginais flutuantes¹².
- Se o salto topológico não seguir a progressão natural de leitura induzida pela árvore RXYC (por exemplo, transitando do meio de um corpo textual para um cabeçalho extremo na borda *Y-max*), a expansão **aborta imediatamente** o realce (*break statement*), limitando de forma conservadora a anotação para evitar os catastróficos vazamentos intertextuais³.

Esta técnica explica fundamentalmente a generalização da heurística. Não estamos implementando "se a fonte for pequena, ignore, deve ser rodapé". Estamos afirmando que a violação drástica da hierarquia de vales espaciais combinada ao decréscimo de evidência lexical define a interrupção segura. Isto assegura que não convertamos o objeto estrutural em polígono de imagem e erradicamos a patologia da extensão vazada simultaneamente.

6. Arquitetura do Pipeline de Avaliação de Candidatos

Com os fundamentos da localização local (SW), desambiguação contextual (W3C) e topologia geométrica (RXYC) estabelecidos, o código contido em `resolvePendingIndices.ts` deve sofrer uma modernização arquitetural paradigmática, desativando a estrutura sequencial condicionada e introduzindo o **Pipeline Gerador e Avaliador de Candidatos**

Multidimensionais.

6.1 O Contrato Estrutural do Objeto Candidato

Diferentes abordagens analisam o documento simultaneamente ou assincronamente. Todas elas produzem e injetam objetos do tipo `MatchCandidate` num repositório temporário da página ativa. Este modelo garante a desacoplagem entre os produtores de evidência e os julgadores de mérito.

```
TypeScript
// Interface base representativa da entidade Candidato
interface MatchCandidate {
  // Topologia Local
  startNodeIndex: number
  startOffset: number
  endNodeIndex: number
  endOffset: number
  pageNumber: number

  // Evidências Linguísticas e Léxicas
```



```

matchedText string
textSimilarityScore number // De 0.0 a 1.0 (ex: Levenshtein ratio ou SW Score)
prefixContextScore number // Correspondência com importedPdfTextContext.prefix
suffixContextScore number // Correspondência com importedPdfTextContext.suffix

// Evidências de Geometria Documentológica
pdfBoundingBox BoundingBoxData
distanceToAtlasBBox number // Inverso da distância euclidiana dos centroides
layoutContinuityScore number // Avaliação de não-violação da árvore RXYC

// Rastreabilidade de Diagnóstico
generatorStrategy string // Qual gerador submeteu (ex: 'SmithWatermanWindowed')
confidenceScore number // Atingido pós-julgamento (a ser preenchido)

```

6.2 Os Geradores de Candidatos (Generators)

O *pipeline* instancia os seguintes geradores, os quais executam heurísticas sobre as entidades expostas:

1. **Gerador de Equivalência Literal (Whitespace Normalized):** Varre a camada unificada de texto procurando pela versão padronizada da *string* completa originária. Eficaz em mais de 70% das ocorrências límpidas onde o modelo de origem foi imaculadamente transposto para PDF.js. O seu baixo custo de inicialização garante um processamento vertiginoso³¹.
2. **Gerador de Alinhamento Sub-Lexical (Alphanumeric/Soft-Hyphen Stripped):** Intervém sobre a mesma massa de caracteres aplicando purificação contra hifens flexíveis nativos (, hifenização discricionária) e sinais de pontuação espúrios interligados à falhas estruturais, operando por busca regular.
3. **Gerador Restrito por Janela de Bounding Box (BBox Constraint Generator):** Compara a bbox injetada pelo marcador Atlas.ti com os polígonos disponíveis na renderização do PDF.js, capturando cirurgicamente um agrupamento de textLayerNodes cuja intersecção poligonal exceda um índice aceitável. Utiliza o texto em bruto que reside nestas caixas como núcleo primário de uma correspondência léxica local.
4. **Gerador Elástico de Smith-Waterman:** Funciona como a rede salva-vidas mais complexa para as anotações cujas ligaturas fraturaram o texto contínuo, as quais provocam reações binárias de rejeição nas tentativas antecessoras. Localiza o melhor núcleo possível de alinhamento com tolerância a distorções pontuais de inserção/deleção derivadas da renderização do navegador gráfico⁸.
5. **Gerador Propagador Vizinho (Neighbor Page Expansion):** Propaga os alinhamentos até às bordas de pageNumber - 1 e pageNumber + 1 usando unicamente a lógica de junção descrita pelo final topológico absoluto (a última linha da coluna direita do bloco inferior) conectando-se ao vértice absoluto inicial (primeira linha da coluna esquerda do bloco superior) da página posterior²¹.

A coexistência harmoniosa do BBox como guia indutivo para a localização (*hint*) é uma constrição leve (*soft constraint*). A sua presença penaliza aproximações distantes, mas recusa peremptoriamente a conversão brutalística do resquício textual orgânico para a primitiva genérica do Atlas, conservando o marcador na sua taxonomia *PdfMarker*.

6.3 O Motor de Avaliação Multidimensional (Scorer)

Após a recolha irrestrita de todos os candidatos submetidos, o motor procede com a medição de uma heurística cumulativa, reduzindo as métricas tridimensionais a um fator tangível de

Confiança (C). A margem diferencial para eleger o melhor candidato sobre o segundo melhor determina a imunidade contra falsos positivos sistêmicos ancorados em *boilerplate*.

O polinômio determinístico para extração da confiança pode ser modelado abstratamente como:

$$C = \omega_1 S_{text} + \omega_2 S_{geo} + \omega_3 S_{context} - \rho_{penalty}$$

Nesta equação, cada coeficiente detém a responsabilidade matemática pela mitigação de um domínio de erro específico:

- $S_{text} \in [0, 1]$ reflete a integridade semântica (grau de sobreposição mútua verificado, ex., via pontuação normalizada de SW⁸).
- $S_{geo} \in [0, 1]$ expressa a coerência posicional, comumente o reflexo inverso normalizado da distância euclidiana entre a estimativa de centroide oriunda das restrições nativas do QDPX e o núcleo extraído dos nós textuais avaliados no DOM.
- $S_{context} \in [0, 1]$ mede a validação contextual através dos prefixos e sufixos adjacentes (a matriz extraída do importedPdfTextContext), punindo instâncias isoladas sem aderência às frases vizinhas.
- A penalidade $\rho_{penalty}$ subtrai confiança imediatamente se a extração demonstrar irregularidades profundas perante a topologia subjacente produzida pelo extensor XY-Cut, como cruzamento não provocado em calhas horizontais imensas.

Uma parametrização de pesos provisória visando favorecer uma convergência ágil aos

requisitos seria $\omega_1 = 0.50$, $\omega_2 = 0.30$, e $\omega_3 = 0.20$. Se um trecho *boilerplate*

apresenta uma equivalência semântica plena ($S_{text} \approx 1.0$) na base do documento (rodapé), mas a coordenada originária subscrita pelo QDPX assinalava o bloco central superior, o

coeficiente S_{geo} reduzirá a contribuição da zona espacial distorcida drasticamente. Sem o

patrocínio do contexto lateral contíguo ($S_{context} \approx 0$), a integral deste falso positivo nunca ultrapassará a pontuação produzida por uma correspondência genuína com pequenos erros de ligaturas na porção correta do texto principal, elidindo completamente a repetição

catastrófica dos erros documentados no D1.

7. Retenção Conservadora: Estratégia de Preservação em Baixa Confiança

Uma premissa inexorável do projeto impedia a conversão coerciva e falha das seleções duvidosas ou mutiladas numa marcação poligonal bruta (PdfShapeMarker) ou num estado cíclico e indesejado de persistência infinita no campo *pendente*.

A metodologia preconizada introduz, deste modo, a classe da "Resolução Degradada" ou Conservadora. Quando absolutamente nenhum candidato propiciado pelo percurso do motor

multidimensional lograr transpor o limiar pré-estabelecido de Confiança Estrita (T_{strong}), o sistema implementa um modo de preservação amadurecido³³.

1. O avaliador elegerá, independentemente, o modelo primaz (C_{max}) existente na seleção candidata, resgatando a evidência vestigial disponível na avaliação (uma aproximação geométrica pálida acompanhada de alinhamento léxico fracionário).
2. A máquina preenche todos os parâmetros de localização e offset no *PdfMarker*, sem remetê-lo ao contingente pendente.
3. O resolvidor anexa, obrigatoriamente, uma assinatura de metadado permanente ao objeto instanciado no JSON, nomeada transitoriamente como *resolutionQuality*: 'degraded', inserindo instâncias subordinadas documentativas (*diagnostics_expectedText*, *diagnostics_matchedText* e *diagnostics_confidence*).
4. O sistema interage com o contexto visual, permitindo à UI nativa do Obsidian identificar e traduzir este ruído semântico. A renderização do sublinhado adquire estilos de alerta ou opacidade translúcida, noticiando visual e organicamente o pesquisador que aquela cota qualitativa repousa sob escrutínio informacional.

Este subterfúgio inteligente mantém o contrato intocado, estagnando as cifras pendentes no absoluto zero e enjaulando perfeitamente a diferença analítica entre a integridade algorítmica de uma estruturação validada (*structural resolution*) e uma correspondência óptica puramente deficiente (*visual quality*)⁴. O marcador corrompido, sublinhado e destacado visualmente, tem utilidade manifesta superior a um objeto silenciado no fundo falso dos processos suspensos. A transparência na demonstração da dúvida do sistema nutre a integridade inerente a ferramentas especializadas em análise categórica qualitativa (CAQDAS).

8. Plano Incremental de Implementação

Substituir iterativamente a arquitetura num corpo produtivo coeso encerra riscos operacionais extensos. O refatoramento não deve assumir características de uma intervenção única em grande escala (*Big Bang*), mas deve desenrolar-se segundo camadas autotestáveis.

- **Fase 1: Transição do Fluxo de Controle para Pipeline Produtor/Avaliador.**
Desabilitar as sequências condicionais imperativas de tentativa de *matching* aninhado (no *resolvePendingIndices.ts*) para injetar a matriz de geração contínua descrita acima. A geração do candidato é populada unicamente pelos modelos clássicos preexistentes (texto livre e normalizações alfanuméricas simples). Um classificador ingênuo com pesos

lineares assume a eleição do MatchCandidate. O crivo prático é a inalterabilidade no desempenho geral verificado no relatório (*smoke-test*), assegurando os marcadores consolidados sem criar pendências inéditas.

- **Fase 2: Retenção Diagnóstica e Exposição Gradativa de Falhas.**

Modificação profunda dos mecanismos restritivos da falha absoluta. Instituição formal da tag `resolutionQuality: 'degraded'`. Todo processo rejeitado ou aquém do critério analítico mínimo passa a repousar no índice serializado (*data.json*), municiado das métricas diagnosticadas de divergência léxica para alimentação direta do escrutinador estatístico escrito em Python.

- **Fase 3: Geometria Segura via Árvore Topológica (XY-Cut Light).** Implementação e conexão das avaliações do leiaute. Substituir o extensor baseado puramente no fluxo visual contínuo pelo extensor que consulta e respeita as bordas descritas pelo Recursive XY-Cut ao sobrevoar os *bounding boxes* do `textLayer`. O escopo empírico ditará a supressão progressiva ou imediata das interrupções precoces (truncamento ou 16 ocorrências *covered-prefix* catalogadas no D1), restringindo contramedidas indesejadas que afetam e desaguam nos apêndices e cabeçalhos indevidos¹².

- **Fase 4: Imersão Robusta da Âncora usando Programação Dinâmica (Smith-Waterman).**

O injetor final implanta as formulações matemáticas das funções de alinhamento com penalidades afins locais. Direcionada às janelas geográficas identificadas pelas âncoras nominais ou coordenadas adjacentes das *bounding boxes* elásticas. Espera-se a dizimação irrestrita das 3 incidências teimosas de âncoras cravadas equivocadamente em posições internas (Deslocamento Interno: *covered-inside-expected* fora do D1).

9. Riscos, Limitações e Estados de Falha Absoluta (Fail States)

Toda a arquitetura heurística está intimamente entrelaçada com ameaças endêmicas no contexto da modelagem. O maior vetor de risco originar-se-á do afinamento excessivamente liberal das penalidades afins embutidas no algoritmo sub-lexical (Smith-Waterman).

Se os parâmetros de permissividade à penalidade estendida γ_{extend} forem ajustados de maneira branda, a engrenagem prosseguirá engolindo segmentos textuais integrais e quebras espaciais ilógicas a fim de encontrar as três ou quatro palavras perdidas do sufixo. Este relaxamento induz ao esmagamento contínuo sobre áreas vizinhas indesejáveis.

O modelo arquitetural deve admitir também as limitações e a imperiosidade incontestável da falência quando o substrato fundamental corrompeu.

- **Corrupção Abissal do Base-OCR:** Na contingência infeliz do ecossistema PDF.js gerar puro ruído codificado incompreensível (lixo de caracteres, ex.: "Å¶¿ø") numa proporção predominante da zona topológica (superior a 80%), acompanhado simultaneamente de flutuações e *shifts* catastróficos das coordenadas geométricas transportadas do Atlas.ti, o sistema admitirá a inexorável derrota.
- A máxima algorítmica prevalece sem desculpas: "A automação recuará à degradação ou abdicará antes de corromper uma métrica ou marcador visual já classificado como

funcional e ileso." Neste estado de falência contínua, o sistema assegura à camada superior analítica humana (o utilizador final) que aquele contexto específico escapa irremediavelmente às restrições compreensíveis da máquina.

10. Teste Offline, Calibração Heurística e Prevenção de Regressões

Dado que a arquitetura proíbe rigorosamente o uso sistemático de execuções automatizadas em ambientes contíguos do Obsidian (*End-to-End* autônomo), a infraestrutura processual depende impreterivelmente das capacidades avançadas e consolidação comparativa do *script* local `audit_qdpx_pdf_import.py`.

A mecânica analítica desenhada para a maturação, calibragem contínua dos modelos

matemáticos (os pesos dimensionais do vetor de decisão S) repousará na confecção iterativa da Matriz de Qualidade Estática de *Snapshots*:

1. **Geração e Manutenção do Artefato de Referência (*Ground Truth*):** O repositório retém as predefinições espaciais e contínuas dos 203 modelos do documento de suporte inalterado `_qualia-pdf-marker-coverage-audit.json`. Toda a reavaliação incide na diferença perante o estado original auditado.
2. **Métrica de Integração de Resolução Estrutural (M_{SR}):** Divisão quantitativa direta das ocorrências semânticas e instâncias puramente textuais marcadas vs as originais documentadas, sendo a tolerância estática tolerada fixa num Rácio de 1.0 absoluto.
3. **Avaliação Dimensional de Desvios (Distância de Levenshtein Bidirecional):** Ao varrer sequencialmente o fluxo extraído pós-conversão contra a raiz lexical transportada (*string* crua do QDPX). O decréscimo paulatino na variância de Levenshtein (Média do Dataset) sinaliza matematicamente o saneamento vitorioso e a aniquilação gradativa do erro fenomenológico do subgrupo truncado (*covered-prefix*).
4. **Auditoria Espacial de Falsos Positivos Geométricos:** Algoritmo estático no Python efetuando o cruzamento da projeção de matriz Atlas-BBox nativa face aos índices armazenados permanentemente dentro do *snapshot* de dados json (`data.json`).

Variações anômalas severas nas coordenadas (Δ_{px}) descortinam silenciosamente, no limiar da pré-publicação, as resoluções infelizes que escorregaram entre colunas divergentes, impedindo a injeção regressiva nas versões vindouras das implementações do modelo.

Ao estruturar este conjunto métrico, a evolução da base de código processa a estabilidade das heurísticas contidas sem perturbar o ecossistema ou exigir intervenções complexas, garantindo e demonstrando, analiticamente, a eficácia inabalável e o poder semântico da presente abordagem arquitetural proposta, cancelando a consolidação final para a superação segura do *matching* em PDFs acadêmicos heterogêneos.

Works cited

1. A Benchmark and Evaluation for Text Extraction from PDF,

- <https://ad-publications.cs.uni-freiburg.de/benchmark.pdf>
2. PDF to Text, a challenging problem - Hacker News,
<https://news.ycombinator.com/item?id=43973721>
 3. Potential of natural language processing for metadata extraction from environmental scientific publications - SOIL,
<https://soil.copernicus.org/articles/9/155/2023/soil-9-155-2023.html>
 4. Guide to Evaluating PDF.js - Apryse,
<https://apryse.com/blog/pdf-js/guide-to-evaluating-pdf-js>
 5. LayoutLM: Pre-training of Text and Layout for Document Image Understanding - arXiv, <https://arxiv.org/pdf/1912.13318>
 6. GitHub - BobLd/DocumentLayoutAnalysis: Document Layout Analysis resources repos for development with PdfPig.,
<https://github.com/BobLd/DocumentLayoutAnalysis>
 7. Modified X-Y Cut Algorithm for OCR Layout | PDF | Optical Character Recognition - Scribd,
<https://www.scribd.com/document/128242299/A-Modified-Recursive-X-Y-Cut-Algorithm-for-Solving-Block-Ordering-Problems>
 8. A new approach to sequence comparison: Normalized sequence alignment | Request PDF - ResearchGate,
https://www.researchgate.net/publication/12033610_A_new_approach_to_sequence_comparison_Normalized_sequence_alignment
 9. GNAT: A General Narrative Alignment Tool - ACL Anthology,
<https://aclanthology.org/anthology-files/pdf/emnlp/2023.emnlp-main.904.pdf>
 10. Ask HN: What Are You Working On? (April 2026) - Hacker News,
<https://news.ycombinator.com/item?id=47741527>
 11. Optimized XY-cut for determining a page reading order - ResearchGate,
https://www.researchgate.net/publication/4214809_Optimized_XY-cut_for_determining_a_page_reading_order
 12. XY-Cut++: Advanced Layout Ordering via Hierarchical Mask Mechanism on a Novel Benchmark - arXiv, <https://arxiv.org/html/2504.10258v1>
 13. Historical Document Digitization through Layout Analysis and Deep Content Classification - IRIS Unimore,
<https://iris.unimore.it/bitstream/11380/1103792/2/main.pdf>
 14. [Reading Order] Classical & Geometric Algorithms Baseline (Family A) · Issue #37 · krishaygarg/AdaRemediator - GitHub,
<https://github.com/krishaygarg/AdaRemediator/issues/37>
 15. Smith–Waterman algorithm - Wikipedia,
https://en.wikipedia.org/wiki/Smith%E2%80%93Waterman_algorithm
 16. Matching Algorithms and Use Cases - IBM,
<https://www.ibm.com/docs/en/wm-onedata/10.11.0?topic=guide-matching-algorithms-use-cases>
 17. An Algorithm for Generation of Attack Signatures Based on Sequences Alignment - Semantic Scholar,
<https://pdfs.semanticscholar.org/c601/beac2df8c4c1a13eb79f3aff7449f6e4b0b9.pdf>

18. AGNES: Adaptive Graph Neural Network and Dynamic Programming Hybrid Framework for Real-Time Nanopore Seed Chaining - arXiv, <https://arxiv.org/html/2510.16013v3>
19. ISSA: Generic Pipeline, Knowledge Model and ... - ResearchGate, https://www.researchgate.net/profile/Franck-Michel-3/publication/364535730_ISS_A_Generic_Pipeline_Knowledge_Model_and_Visualization_Tools_to_Help_Scientists_Search_and_Make_Sense_of_a_Scientific_Archive/links/635792ca6e0d367d91c4b684/ISSA-Generic-Pipeline-Knowledge-Model-and-Visualization-Tools-to-Help-Scientists-Search-and-Make-Sense-of-a-Scientific-Archive.pdf
20. The Ontolex Module for Frequency, Attestation and Corpus Information, <https://acoli-repo.github.io/ontolex-frac/>
21. Web Annotation Data Model - W3C, <https://www.w3.org/TR/annotation-model/>
22. Web Annotation - Devopedia, <https://devopedia.org/web-annotation>
23. Knowledge Graph and Services to Advance COVID-19 Research - SciSpace, <https://scispace.com/pdf/covid-on-the-web-knowledge-graph-and-services-to-advance-dwrbf051uw.pdf>
24. Retrieve bounding box of text on a page · Issue #5643 · mozilla/pdf.js - GitHub, <https://github.com/mozilla/pdf.js/issues/5643>
25. How to calculate bounding rectangle for each text item? · Issue #8655 · mozilla/pdf.js, <https://github.com/mozilla/pdf.js/issues/8655>
26. Segmentation Of Layout-Based Documents - Uni Freiburg, https://ad-publications.cs.uni-freiburg.de/theses/Bachelor_Elias_Kempf_2021.pdf
27. Text Classification and Layout Analysis for Document Reassembling - Computer Vision Lab, <https://cvl.tuwien.ac.at/wp-content/uploads/2014/12/tr-13.pdf>
28. TabbyPDF: Web-Based System for PDF Table Extraction: 24th International Conference, ICIST 2018, Vilnius, Lithuania, October 4–6, 2018, Proceedings - ResearchGate, https://www.researchgate.net/publication/327269137_TabbyPDF_Web-Based_System_for_PDF_Table_Extraction_24th_International_Conference_ICIST_2018_Vilnius_Lithuania_October_4-6_2018_Proceedings
29. 05/08/2026 10:24 Layout analysis and content classification in digitized books / Corbelli, A., Baraldi, L., Balducci, F., Grana,, https://iris.unimo.it/retrieve/e31e124c-98c2-987f-e053-3705fe0a095a/2016_IRCD_L.pdf
30. Document Layout Analysis · UglyToad/PdfPig Wiki - GitHub, <https://github.com/UglyToad/PdfPig/wiki/Document-Layout-Analysis>
31. Robust, Scalable Detection of Text Containment in Large Web-Crawled Corpora - arXiv, <https://arxiv.org/pdf/2607.10020>
32. Taxamatch, an Algorithm for Near ("Fuzzy") Matching of Scientific Names in Taxonomic Databases | PLOS One - Research journals, <https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0107510>
33. Swampunk: Rough Consensus and Running Code in Brains, Machines, and Society - jonny saunders, https://jon-e.net/dissertation/assets/swampunk_repo.pdf
34. From Unstructured PDF Files to Contract Intelligence: A Local LLM RAG Pipeline

for Extracting Demurrage Terms and Conditions - MIT CTL,
<https://ctl.mit.edu/sites/default/files/documents/from-unstructured-pdf-files-to-contract-intelligence-capstone.pdf>